NVIDIA TAO Toolkit 学习摘要

TAO (Train, Adapt, Optimize) Toolkit 是 NVIDIA 推出的低代码 AI 工具链,基于迁移学习和模型优化技术,帮助开发者快速构建、微调并优化适用于边缘设备的轻量级模型。

图 1: 手动下载 TAO 包

获取 NGC API KEY:

\$ nvapi-6hFAC3DuMKCW 5mQebeV4JCtz956eR27C3OIgoDuxZ0q3D00TB1bg2Rihtbek1iH

```
yuervm@LAPTOP-5MK05CJF: × + v - - - ×

yuervm@LAPTOP-5MK05CJF:~$ docker login nvcr.io

Username: $oauthtoken

Password:
Login Succeeded
yuervm@LAPTOP-5MK05CJF:~$ |
```

图 2: 登录成功

```
Installing collected packages: wcwidth, pure-eval, ptyprocess, typing_extensions, traitlets, tornado, six, p yzmq, pygments, psutil, prompt_toolkit, platformdirs, pexpect, parso, packaging, nest-asyncio, executing, de corator, debugpy, asttokens, stack_data, python-dateutil, matplotlib-inline, jupyter-core, jedi, ipython-pyg ments-lexers, comm, jupyter-client, ipython, ipykernel
Successfully installed asttokens-3.0.0 comm-0.2.2 debugpy-1.8.14 decorator-5.2.1 executing-2.2.0 ipykernel-6.29.5 ipython-9.3.0 ipython-pygments-lexers-1.1.1 jedi-0.19.2 jupyter-client-8.6.3 jupyter-core-5.8.1 matplo tlib-inline-0.1.7 nest-asyncio-1.6.0 packaging-25.0 parso-0.8.4 pexpect-4.9.0 platformdirs-4.3.8 prompt_tool kit-3.0.51 psutil-7.0.0 ptyprocess-0.7.0 pure-eval-0.2.3 pygments-2.19.2 python-dateutil-2.9.0.post0 pyzmq-2 7.0.0 six-1.17.0 stack_data-0.6.3 tornado-6.5.1 traitlets-5.14.3 typing_extensions-4.14.0 wcwidth-0.2.13 (launcher) yuervm@LAPTOP-5MKOSCJF:~$ python -m ipykernel install --user --name launcher --display-name "laun cher"
Installed kernelspec launcher in /home/yuervm/.local/share/jupyter/kernels/launcher (launcher) yuervm@LAPTOP-5MKOSCJF:~$
```

图 3: 设置 Python 环境

图 4: 手动下载和安装 nvidia container

图 5: 手动下载和安装 nvidia container toolkit

图 6: 安装 nvidia container 包

```
yuervm@LAPTOP-5MKO5CJF: ×
                              4. classification_tfl
                               5. classification_tf2
                               6. deformable_detr
                               7. detectnet_v2
                               8. dino
                               9. dssd
                              10. efficientdet_tf1
11. efficientdet_tf2
12. faster_rcnn
13. grounding_dino
                              14. mask_grounding_dino
15. mask2former
16. lprnet
                               17. mask_rcnn
18. ml_recog
19. multitask_classification
                               20. ocdnet
                               21. ocrnet
                               22. optical_inspection
                               23. retinanet
                               24. segformer
                               25. ssd
                               26. trtexec
                               27. unet
                              28. yolo_v3
29. yolo_v4
30. yolo_v4_tiny
format_version: 3.0
toolkit_version: 5.5.0
published_date: 08/26/2024
.
(launcher) yuervm@LAPTOP-5MKO5CJF:~/tao_tutorials$ chmod +x setup/quickstart_launcher.sh
```

图 6: 成功安装 TAO Launcher 并添加权限

TAO 需要特定的 CUDA、TensorRT 和 Python 依赖组合,Docker 容器可确保环境一致,避免与主机系统冲突。TAO Toolkit 依赖 CUDA 进行 GPU 加速计算,所有训练和推理任务均通过 CUDA 调用 GPU 算力,必须安装与 TAO 版本匹配的 CUDA。TAO 生成的模型可通过 TensorRT (基于 CUDA) 优化,显著提升边缘设备(如 Jetson)的推理速度。TAO Launcher 是一个基于 Python 的轻量级命令行界面,充当基于 PyTorch、TensorFlow 和 TensorRT 构建的 TAO 容器。

NVIDIA TAO Toolkit 的核心流程始于从 NGC (NVIDIA GPU Cloud) 下载预训练模型,用户可通过 Jupyter Notebook 快速启动迁移学习任务。首先在 NGC 模型库中选择适合的预训练模型(如 ResNet 或 YOLOv4),然后使用 TAO 提供的 Jupyter Notebook 模板加载模型并配置训练参数,包括数据路径、学习率和训练轮数等。在 Notebook 中,用户可以用少量标注数据对模型进行微调,TAO 会自动处理数据增强和分布式训练等复杂过程。训练完成后,通过内置工具对模型进行剪枝和量化优化,最终导出为 TensorRT 格式,直接部署到Jetson 等边缘设备。整个过程在 Docker 容器中完成,确保环境一致性,同时支持实时监控训练指标和可视化模型性能,显著降低了从模型开发到边缘部署的技术门槛。